

林泽佳

✉ linzj39@mail2.sysu.edu.cn

🏠 zejia-lin.github.io

☎ 18022302700

🗨 Next-Ways

关键词: GPU, LLM, 训推优化, 基模实习经历

- 熟悉计算机系统和体系结构, LLM 推理和 RL 训练系统优化经验, 熟悉 CUDA, SGLang, veRL。3 篇一作 GPU 优化论文 (1A2B), 聚焦 GPU 资源共享、任务调度, LLM 训推框架。
- 扎实的工业界实践: 月之暗面 Kimi 实习中; 微信搜索青云计划实习 19 个月, 科研论文成功落地。

🎓 教育背景

中山大学, 广州 (985, 双一流, 国家超级计算广州中心) 2022 年 9 月 – 2027 年 6 月 (预计)
计算机科学与技术 博士研究生在读 导师: 张献伟、卢宇彤

西北工业大学, 西安 (985, 双一流) 2018 年 8 月 – 2022 年 6 月
软件工程 本科 GPA 排名: 22 / 259 优秀毕业生

📄 研究成果

- [CCF-A, ASPLOS'26, 一作] Bullet: Boosting GPU Utilization for LLM Serving via Dynamic Spatial-Temporal Orchestration. *The 31st ACM International Conference on Architectural Support for Programming Languages and Operating Systems*, 2026.
- [CCF-B, LCTES'24, 一作] MixPert: Optimizing Mixed-Precision Floating-Point Emulation on GPU Integer Tensor Cores. *The 25th ACM SIGPLAN/SIGBED International Conference on Languages, Compilers, and Tools for Embedded Systems*, 2024.
- [CCF-B, ICCD'23, 一作] KeSCo: Compiler-based Kernel Scheduling for Multi-task GPU Applications. *The IEEE 41th International Conference on Computer Design*, 2023.
- [CCF-A, TACO, 二作] HuntKTm: Hybrid Scheduling and Automatic Management for Efficient Kernel Execution on Modern GPUs. *ACM Transactions on Architecture and Code Optimization*, 2025.
- [DAC'25, CCF-A, 二作] GoPTX: Fine-grained GPU Kernel Fusion by PTX-level Instruction Weaving. *The 62nd ACM/IEEE Design Automation Conference*, 2025.

🧑‍💻 实习经历

月之暗面, Kimi · AI Infra 实习 2026 年 6 月 – 现在

- 参与稀疏注意力推理算法-系统协同设计和推理优化。

腾讯, 微信事业群/搜索应用部 · AI Infra 实习 (青云计划) 2024 年 12 月 – 2026 年 6 月

- 研究 LLM 推理性能优化, 产出一篇 ASPLOS'26 论文 (接收率: 10.6%), 主导其在内部自研框架中落地, 在 SGLang Beijing Meetup 中被宣讲。
- 研究 RL 性能优化, 128 卡 Qwen3-235B 权重更新时间 208s → 1.4s, 端到端训练时间减少 15%。

腾讯, 微信事业群/微信支付线 · 后台开发实习 2021 年 7 月 – 2021 年 9 月

- 负责研效提升工作, 用 Django 搭建分布式的企业微信内部机器人, 收集和自动回复测试环境相关问题。接入腾讯内部 TAPD 和七彩石项目管理系统, 完善问题流程追踪管理, 自动更新缺陷库。

🔧 项目经历

LLM 推理优化：GPU 内 PD 分离

微信搜索实习 (CCF-A)

- 问题: 计算密集的 prefill 和访存密集的 decode 天然适合在 GPU 上并发执行，提升利用率和吞吐。然而，并发执行时 PD 会相互干扰，如何对其进行有效控制来满足 SLO 是一个挑战。
- 贡献: 进行 GPU 时空划分，对不同 SM 数量的计算、访存和通信性能进行分析和建模，预测不同 SM 比例的 PD 性能。基于 SGLang 实现 GPU 内 PD 分离，在线监控 PD 进度并动态调整 SM 分配比例。
- 成果: 在微信搜索真实 workload 中吞吐提升 19%，端到端延迟降低 26%，P99 延迟降低 1.9×，成果发表于 ASPLOS'26 并在内部自研框架中落地。

RL 训练优化：并行度转换和高效权重更新

微信搜索实习

- 问题: RL 训练权重更新需要处理推理 (Rollout) 和训练的不同并行度转换 (DP/PP/TP/EP/CP)，现有框架依赖 AllGather 通信，传输大量冗余权重，通信开销大且时间长。
- 贡献: 计算不同并行度下需要接收/发送的权重分片，使用 P2P 进行权重更新，不传递冗余权重。
- 成果: 128 卡 Qwen3-235B 权重更新时间 208s → 1.4s，端到端训练时间减少 15%。

Kernel 自动并发调度优化

科研项目 (CCF-A & B)

- 应用中有部分 kernel 可在不同 CUDA stream 中并发执行，但存在复杂依赖关系。我们在编译期静态分析 kernel 依赖，自动插入多流和同步等代码，免去手动编程的负担。
- 基于 LLVM 实现编译优化，并实现多 GPU 的任务分发运行时，单/多卡性能分别提升 28% 和 33%。成果发表于 ICCD'23 和 TACO 期刊。

Tensor Core FP32 计算模拟

科研项目 (CCF-B)

- Tensor Core 无法计算 FP32 矩阵乘，我们在 Tensor Cores 上用 INT8 模拟 FP32 矩阵乘，与 CUTLASS 中基于 TF32 模拟 FP32 的方法相比性能提升 21%，且精度保持一致。成果发表于 LCTES'24。

</> 专业技能

- 语言和编译: C/C++, CUDA, Python, LLVM
- GPU 和 AI 生态: NVIDIA nsys/ncu, cuBLAS, PyTorch, vLLM, SGLang, veRL
- CCF CSP 认证: Top 5.2%
- 英语六级: 610 / 710

★ 获奖情况

ACM ASPLOS Student Travel Grant	2026 年
中山大学 一等奖学金	2024, 2023, 2022 年
腾讯奖学金 一等奖 (3%)	2023 年
西北工业大学 优秀毕业生	2022 年
西北工业大学 一等奖学金	2021, 2020, 2019 年
中国高校计算机大赛微信小程序应用开发赛 全国二等奖 (5%, 参赛队长)	2020 年 8 月

📄 学术服务

- ACM ASPLOS/EuroSys/SOSP, Artifact Evaluation Committee
- IEEE NAS 2024, Sub-reviewer
- IEEE ICPADS 2022, Sub-reviewer