

林泽佳

✉ linzj39@mail2.sysu.edu.cn 🌐 zejia-lin.github.io ☎ 18022302700 🗨 Next-Ways

关键词: GPU, LLM, 推理优化, 编译优化

- 熟悉计算机系统和体系结构, LLM 推理和 RL 训练系统, 熟悉 CUDA, SGLang, veRL, Megatron。
- 微信搜索 Infra 实习一年以上, 3 篇一作 GPU 优化论文 (1A2B), 聚焦 GPU 资源共享、任务调度。

🎓 教育背景

中山大学, 广州 (985, 双一流, 国家超级计算广州中心) 2022 年 9 月 – 2027 年 6 月 (预计)
计算机科学与技术 博士研究生在读 导师: 张献伟、卢宇彤

西北工业大学, 西安 (985, 双一流) 2018 年 8 月 – 2022 年 6 月
软件工程 本科 GPA 排名: 22 / 259 优秀毕业生

📄 研究成果

- [CCF-A, ASPLOS'26, 一作] Bullet: Boosting GPU Utilization for LLM Serving via Dynamic Spatial-Temporal Orchestration. *The 31st ACM International Conference on Architectural Support for Programming Languages and Operating Systems, 2026.*
- [CCF-B, LCTES'24, 一作] MixPert: Optimizing Mixed-Precision Floating-Point Emulation on GPU Integer Tensor Cores. *The 25th ACM SIGPLAN/SIGBED International Conference on Languages, Compilers, and Tools for Embedded Systems, 2024.*
- [CCF-B, ICCD'23, 一作] KeSCo: Compiler-based Kernel Scheduling for Multi-task GPU Applications. *The IEEE 41th International Conference on Computer Design, 2023.*
- [CCF-A, TACO, 二作] HuntKTm: Hybrid Scheduling and Automatic Management for Efficient Kernel Execution on Modern GPUs. *ACM Transactions on Architecture and Code Optimization, 2025.*

👤 实习经历

腾讯, 微信事业群/搜索应用部, AI Infra 科研实习 2024 年 12 月 – 现在

- 研究 LLM 推理性能优化, 产出一篇 ASPLOS'26 论文 (接收率: 10.6%), 主导其在内部自研框架中落地, 在 SGLang Beijing Meetup 中被宣讲。
- 参与自研 RL 框架建设, RL 性能优化。

腾讯, 微信事业群/微信支付线, 后台开发实习 2021 年 7 月 – 2021 年 9 月

- 负责研效提升工作, 用 Django 搭建分布式的企业微信内部机器人, 收集和自动回复测试环境相关问题。接入腾讯内部 TAPD 和七彩石项目管理系统, 完善问题流程追踪管理, 自动更新缺陷库。

⚙️ 项目经历

LLM 推理优化: GPU 内 PD 分离 微信搜索实习

- 问题: 计算密集的 prefill 和访存密集的 decode 天然适合在 GPU 上并发执行, 提升利用率和吞吐。然而, 并发执行时 PD 会相互干扰, 如何对其进行有效控制来满足 SLO 是一个挑战。
- 贡献: 进行 GPU 时空划分, 对不同 SM 数量的计算、访存和通信性能进行分析和建模, 预测不同 SM 比例的 PD 性能。基于 SGLang 实现 GPU 内 PD 分离, 在线监控 PD 进度并动态调整 SM 分配比例。
- 成果: 在多个开源数据集上平均提升 26% 吞吐, 在微信搜索真实 workload 中端到端延迟降低 11%, P99 TTFT, ITL 分别降低 26%, 2.02 $\times$ 。成果发表于 ASPLOS'26 并在内部自研框架中落地。

Kernel 自动并发调度优化

科研项目

- 应用中有部分 kernel 可在不同 CUDA stream 中并发执行，但存在复杂依赖关系。我们在编译期分析 kernel 依赖，自动插入多流和同步等代码，免去手动编程的负担。
- 基于 LLVM 实现编译优化，并实现多 GPU 的任务分发运行时，单/多卡性能分别提升 28% 和 33%。成果发表于 ICCD'23 和 TACO 期刊。

Tensor Core FP32 计算模拟

科研项目

- Tensor Core 无法计算 FP32 矩阵乘，我们在 Tensor Cores 上用 INT8 模拟 FP32 矩阵乘，与 CUTLASS 中基于 TF32 模拟 FP32 的方法相比性能提升 21%，且精度保持一致。成果发表于 LCTES'24。

</> 专业技能

- 语言和编译: C/C++, CUDA, Python, LLVM
- GPU 相关工具: NVIDIA nsys/ncu, cuBLAS
- AI 生态: PyTorch, vLLM, SGLang, veRL, Megatron
- CCF CSP 认证: Top 5.2%
- 英语六级: 610 / 710

★ 获奖情况

中山大学 一等奖学金	2024, 2023, 2022 年
腾讯奖学金 一等奖	2023 年
西北工业大学 优秀毕业生	2022 年
西北工业大学 一等奖学金	2021, 2020, 2019 年
中国高校计算机大赛微信小程序应用开发赛 全国二等奖 (5%, 参赛队长)	2020 年 8 月

✍ 学术服务

- ACM ASPLOS 2026, Artifact Evaluation Committee
- ACM EuroSys 2026, Artifact Evaluation Committee
- ACM SOSP 2025, Artifact Evaluation Committee
- IEEE NAS 2024, Sub-reviewer
- IEEE ICPADS 2022, Sub-reviewer